全国高校 AI WEB 开发挑战赛 · 参赛作品

车间智答

面向智能制造一线的本地化 AI 知识与故障排查助手

DATA STAYS IN THE FACTORY · ANSWERS STAY TRACEABLE

作品名称	车间智答（Workshop QA）	团队名称	【团队名称】
学校	【学校名称】	团队成员	【成员姓名 1】· 【成员姓名 2】· 【成员姓名 3】
指导教师	【指导教师姓名】	提交日期	2026 年 11 月

VERSION 0.3.0 · TECHNICAL DOCUMENT

数据不出厂 · 离线可用 · 回答可溯源



ABSTRACT

摘要

注塑车间的设备手册、点检标准、故障案例与安全规程分散在 PDF、纸质文件和老师傅经验中，新人遇到报警往往只能翻手册、问师傅，响应慢且口径不一；直接使用通用大模型又存在设备数据外泄、模型编造报警代码与参数的风险。

本作品构建了一套**本地优先的检索增强生成（RAG）问答与故障排查系统。**系统将厂内 Markdown 文档按标题层级与段落切分，使用 bge-m3 生成 1024 维向量并存入 Chroma；提问时检索 top-4 片段，交由本地 Qwen2.5-7B 量化模型流式生成，答案逐句标注出处，资料不足时明确拒答。针对「手册没写但问题属于注塑领域」的灰区，系统在检索分数低于 0.6 或本地模型自评资料不足时自动升级 DeepSeek，并通过 SSE `route` 事件让界面实时显示路径与原因。故障排查采用 12 节点、11 结论的确定性状态机，每一步引用手册原文，走完生成可打印的 A4 处置单。知识库检索同时封装为 MCP 工具，可被其他 AI 应用复用。

实测结果：15 份示例文档、123 个切片；30 条问句校准出 0.6 的拒答阈值（正向最低 0.675、负向最高 0.522）；本地问题 top-1 0.7833、首字 0.25–1.0 s；云端升级用例 top-1 0.6589，正确触发 `route→cloud`；无关问题 0.4242 被拒答且来源为空；诊断链路 6 步生成处置单并通过 A4 打印验证；MCP 客户端调用检索 `max_score=0.8078`。系统已在本地以生产态单端口跑通，公网部署脚本与文档就绪。

作品亮点

- **数据不出厂**：检索、生成、诊断全部在本机 Ollama 完成，云端只处理低置信问题且只发送必要片段。
- **回答可溯源**：引用编号与后端 `sources.index` 同源，展示文档名、编号、章节路径与相似度。
- **知道就说，不知道就拒**：检索阈值 + 生成层自评两层拒答，拒答时来源置空，不列假出处。
- **路径对用户可见**：本地/云端标签、切换原因、检索分数和耗时都在界面上，演示可验证。
- **确定性诊断**：状态机保证安全步骤不被跳过，结论可复现、可追责，输出纸质处置单。
- **能力可复用**：知识库检索做成 MCP 工具，标准客户端即可发现并调用。

关键词：检索增强生成（RAG）；本地大模型；端云协同；故障诊断状态机；MCP；可溯源问答

CONTENTS

目录

1 概述 5
1.1 背景与痛点 5
1.2 产品定义与目标用户 5
1.3 作品亮点 5
2 需求分析 6
2.1 功能需求 6
2.2 非功能需求 6
2.3 范围边界与用户旅程 6
3 系统架构 8
3.1 总体架构 8
3.2 前端与后端结构 8
3.3 数据与存储 8
3.4 技术选型 9
4 AI 方案 10
4.1 RAG 总览与文档切分 10
4.2 向量化与检索 10
4.3 拒答阈值校准与两层拒答 10
4.4 端云协同路由 11
4.5 确定性故障诊断状态机 11
4.6 MCP 工具化与安全可控 12
5 功能实现 13
5.1 问答界面与引用展示 13
5.2 路由可视化与错误处理 14
5.3 故障排查与处置单 14
5.4 知识库管理与检索测试台 15
5.5 SSE 协议与工程结构 16
6 测试与部署 18
6.1 测试方法与功能验收 18
6.2 关键实验数据 18
6.3 性能与部署 19
6.4 安全清单与已知限制 19
7 总结与展望 20
7.1 完成情况 20
7.2 技术创新点与应用创新点 20
7.3 不足与展望 20
A 附录 A AI 生成代码说明 22
B 附录 B 复现与接口 24

CHAPTER 01

概述

1.1 背景与痛点

注塑车间的知识形态很不「数字化」：设备操作手册是 PDF，点检标准贴在机台，故障案例掌握在老师傅手里，安全规程是纸质文件。新人遇到 A-101 温度报警，通常要经历「翻手册找章节 → 问师傅 → 在群里发消息」的过程，响应慢，而且不同人给出的判断标准不一致。

通用大模型看起来是一个直接答案，但放进工厂会碰到三条硬边界：

- **数据边界**：设备参数、工艺配方、故障记录属于厂内数据，不能默认上传公有云；
- **可信边界**：模型会用相似场景的报警代码、参数值「补全」答案，看起来专业，实际无法追责；
- **流程边界**：电气、高温相关的排查必须按安全顺序执行，不能让模型自由决定「下一步问什么」。

因此，作品的目标不是做一个「更会聊天的设备助手」，而是做一个**答案有出处、拒答有依据、路径可解释、数据留在厂内**的车间知识工具。

1.2 产品定义与目标用户

「车间智答」是面向智能制造一线的本地化 AI 知识与故障排查助手。厂内文档进入知识库后，一线人员用自然语言提问，系统在本机完成检索与生成，答案带原文出处；本地资料不足时按配置升级云端；有固定排查路径的故障走状态机向导，输出可打印的处置单。

用户	典型诉求	系统回应
新入职操作工	开机前检查什么、报警怎么处理、参数在哪里看	本地 RAG 问答 + 引用原文，按手册步骤回答
班组长 / 老师傅	快速确认判断标准，把经验沉淀成可查记录	知识库管理、检索测试台、处置单归档
设备工程师	按安全顺序排查电气/温度故障，留下处理依据	诊断状态机、每步手册依据、A4 处置单
安全员	确认回答没有跳过断电、挂牌、冷却等安全步骤	诊断链首节点强制安全确认；回答保留安全提示

1.3 作品亮点

亮点	具体做法
数据不出厂	检索、生成、诊断均在本机 Ollama 完成；云端只处理低置信问题，且只发送问题与必要片段
回答可溯源	每个片段带文档名、编号、章节路径、相似度；引用编号与 `sources.index` 同源生成
两层拒答	检索层 0.6 阈值挡住无关问题；生成层判断资料是否足够；拒答时来源置空
端云协同	低置信自动升级 DeepSeek，SSE `route` 事件让界面实时标注路径与原因
确定性诊断	12 节点 / 11 结论状态机，每步依据手册，可回退，输出可打印处置单
能力可复用	知识库检索封装为 MCP 工具，标准客户端可发现并调用

CHAPTER 02

需求分析

2.1 功能需求

编号	需求	验收标准	状态
FR-01	文档导入与知识库管理	支持 Markdown/txt 导入、切分、向量化、入库；可查看、删除、重建索引	**通过**
FR-02	RAG 流式问答	答案逐字返回；下方列出来源（文档名 + 片段）；点击可查看原文	**通过**
FR-03	无依据拒答	知识库没有相关内容时明确拒答，不编造，不列假出处	**通过**
FR-04	故障排查向导	从症状走完一条完整诊断链；每步有手册依据；可回退；生成结构化处置单并导出/打印	**通过**
FR-05	端云协同路由	低置信自动升级云端；界面标注本地/云端及原因；两种路径均可实测	**通过**
FR-06	MCP 工具封装	知识库检索可被 MCP 客户端调用并返回检索结果	**通过**
FR-07	部署与运维	本地全链路跑通；提供部署脚本、Nginx/systemd 配置与说明	**本地通过，公网待部署**

2.2 非功能需求

维度	要求	实现
数据安全	密钥不入库；设备数据默认不出厂	密钥只在 `backend/.env`（600）；本地优先路由；云端只发必要片段
可用性	断网时本地问答仍可用	Ollama + Chroma 本地运行；云端失败回退为拒答并提示
响应速度	本地首字 < 2 s；云端首字 < 5 s（开发机）	模型常驻、top-4 检索、流式输出；实测本地 0.25–1.0 s，云端 2.35–3.3 s
可解释性	用户能知道答案来自哪、为什么走这条路	引用卡片、路由标签、检索分数、耗时、切换原因全部可见
易用性	车间一线可操作；手机/平板可用	大字号、少层级、示例问题、触控友好；390×844 实测无横向溢出
可维护性	模块边界清晰，答辩可讲清	路由/服务分层；每个核心模块一页讲义式设计说明；验收脚本可复现

2.3 范围边界与用户旅程

明确不做：用户注册/登录、权限管理、多设备类型、真实工厂数据接入、APP 客户端、多模态拍照诊断。这些能力会显著增加账号、权限与数据合规复杂度，当前版本优先把「问答—拒答—路由—诊断」主链路做扎实。

典型旅程：

1. 操作工打开系统，点「开机前检查」示例问题，得到带引用的检查清单；
2. 遇到手册没写的问题，系统自动升级云端，界面标签变蓝并说明原因；
3. 遇到温度异常，进入故障排查，按安全确认 → 现象 → 电阻 → 端子 → 热电偶 → SSR 的顺序检查；
4. 走完生成处置单，打印签字，交设备科复核；
5. 班组长在知识库页上传新手册，重建索引，检索测试台立即验证。

CHAPTER 03

系统架构

3.1 总体架构

系统采用「单页前端 + FastAPI AI 接入层 + 本地模型/向量库 + 可选云端」的四层结构。前端构建产物由 FastAPI 直接托管，生产环境只有一个 8000 端口，Nginx 负责 TLS 与反向代理。

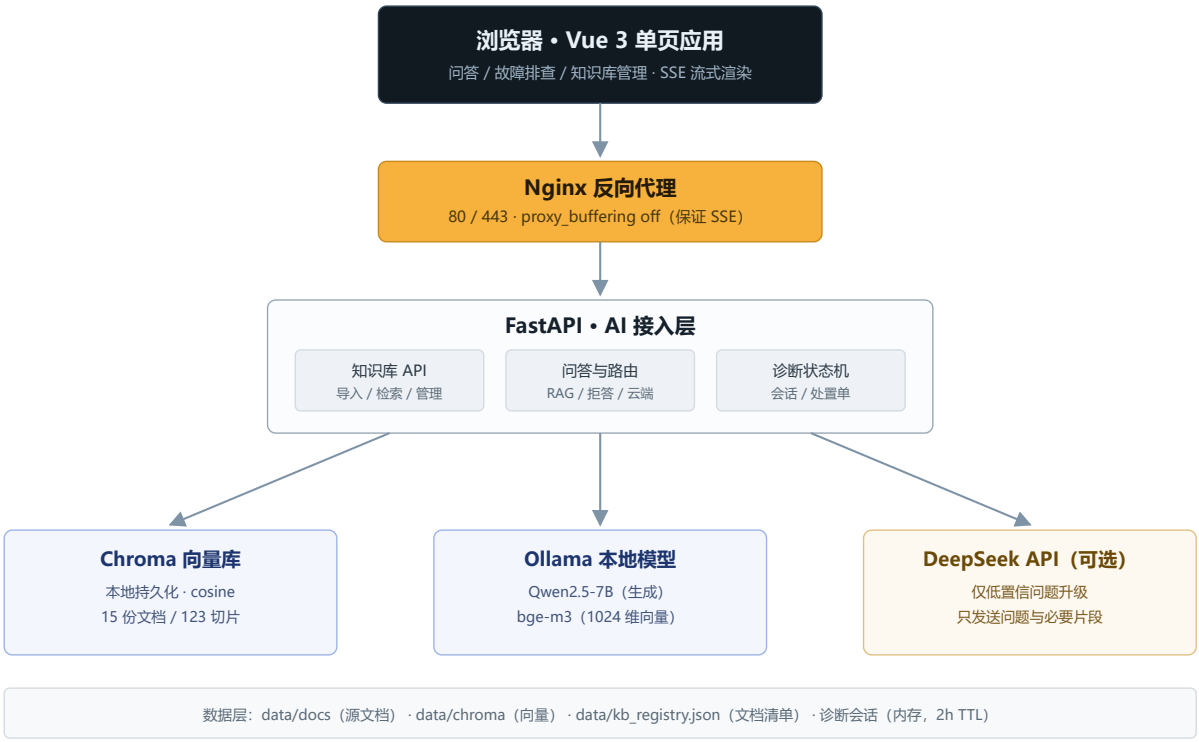


图 3-1　系统总体架构：单端口前端 + AI 接入层 + 本地模型/向量库 + 可选云端

3.2 前端与后端结构

前端采用 Vue 3 `<script setup>` + TypeScript strict，不引入 UI 框架。外壳 `App.vue` 负责导航、健康状态灯和 `KeepAlive`；三个视图各自持有状态，切页不丢问答与诊断进度。路由使用 `location.hash`（`#chat/#diag/#kb`），刷新可恢复。SSE 用 `fetch` + `ReadableStream` 手写解析，支持 POST、长问题和中途停止。

后端按「路由层 + 服务层」划分：`routers/` 只做参数校验与 HTTP 映射，`services/` 承担切分、向量化、检索、生成、路由、诊断。除诊断会话外全部无状态，便于重启与水平扩展；诊断会话存在进程内存并加锁，2 小时 TTL。

3.3 数据与存储

数据	位置	说明
源文档	`data/docs/*.md`	15 份自编注塑机手册、点检、案例、安规、工艺文档
向量与片段	`data/chroma/`	Chroma 持久化集合，余弦距离；每条含正文与元数据
文档清单	`data/kb_registry.json`	文档级记录：编号、标题、类别、版本、切片数、导入时间

数据	位置	说明
诊断会话	进程内存 `_sessions`	当前节点、历史栈、结论；2 小时 TTL，重启丢失
密钥与配置	`backend/.env`	不入库，部署时 600 权限；仓库只留 `.env.example`

3.4 技术选型

层	选择	理由与代价
前端	Vue 3 + Vite + TS，无 UI 框架	组合式 API 适合拆分流式与状态；自建设计令牌保证工业风一致；代价是组件自维护
后端	Python FastAPI	异步流式、类型校验、自动 API 文档；只做 AI 接入层，不引入用户系统
本地模型	Qwen2.5-7B q4_K_M + bge-m3	中文能力强、7B 量化可跑在单卡/CPU；bge-m3 中文语义与长文本表现稳定
向量库	Chroma	本地持久化、零服务依赖、Python 原生；规模上千后可换 Milvus/pgvector
云端	DeepSeek OpenAI 兼容 API	低成本、中文工程语境好；只作低置信兜底
部署	systemd + Nginx + 单端口 FastAPI	环境简单、排查直观；Nginx 关闭缓冲保证 SSE

CHAPTER 04

AI 方案

4.1 RAG 总览与文档切分

系统的默认路径是「检索增强生成」：先把厂内文档变成可检索的片段，再把最相关的几段交给本地模型，模型只许依据这些片段作答。



切分策略：每份文档文首有 `---` 包裹的元数据（文档名、编号、类别、版本、日期）；正文按 Markdown 标题维护标题栈，得到「三、可能原因 > 3.2 加热圈检查」这样的章节路径；节内按空行切段，超过 600 字符才硬切，相邻块保留 80 字重叠。每个块存两份文本：`text` 用于引用展示，`embed_text = 文档名 | 类别 | 章节路径 + 正文` 只用于向量化。这样既保留文档级语义，又不把拼接前缀混进给用户看的原文。

15 份示例文档切出 **123 个切片，平均约 140 字，最长 600 字。**块偏小是刻意的：检索精度优先，宁可多召回几块，也不让一个块混入多个主题。

4.2 向量化与检索

bge-m3 将中文句子映射为 1024 维向量，Chroma 使用 cosine 空间。检索返回的 `distance` 是余弦距离（0～2），系统统一换算为 `score = 1 - distance`，数值越大越相关。取 top-4 的理由是：一个具体操作问题通常 1～2 个章节就能回答，4 段约 500～1000 字，既覆盖不同侧面，又不会把 7B 模型的 4K 上下文挤满；实测调大到 6 段质量无明显提升、首字变慢，调到 2 段会漏掉跨文档的安全规程。

检索结果同时返回 `max_score`、阈值 `min_sim` 与 `has_relevant`，供问答层与 MCP 调用方判断是否需要拒答。

4.3 拒答阈值校准与两层拒答

阈值不是模型自带参数，而是业务判断：误收一条无关资料，可能让模型编造答案；误拒一条有用资料，用户会觉得系统「什么都不知道」。我们用 30 条问句做校准，只检索、不生成：

组别	数量	目的	结果
正向	15	知识库明确能回答	最低 0.675，平均 0.754
负向	8	与注塑车间无关	最高 0.522，平均 0.378
灰区	7	注塑相关但知识库没写	范围 0.436～0.617

正向最低分高于负向最高分，中间存在安全带 `[0.522, 0.675]`。取中点 **0.6**，两侧各留约 0.075 余量，比取 0.675（贴正向最低分）或 0.522（贴负向最高分）更抗样本波动。最初凭经验用 0.5，校准时发现「手机屏幕碎了怎么办」得分 0.522 会被放行，因此改为 0.6。校准脚本最初直接推荐最小正向分 0.675，属于对样本过拟合；后来改为「存在安全带时取中点」，这段修正过程也保留在文档里。

阈值不是万能的。灰区问题（注塑相关、知识库没写）可能落在 0.6 附近，所以系统用两层拒答：

层	触发条件	行为
检索层	`max_score < 0.6`	不调用本地模型；auto 模式直接上云，kb_only 直接拒答
生成层	过了阈值，但模型判断资料不足	输出固定拒答语；auto 模式缓冲后带资料升级云端
路由层	云端也拒答 / 云端不可用	返回云端拒答或回退本地拒答，`sources=[]`

生成层拒答时服务端把 `sources` 置空，避免界面出现「拒答但列了一堆出处」的自相矛盾展示。

4.4 端云协同路由

路由发生在检索之后、生成之前/之中，分四种情况：

情况	行为	界面
命中（≥0.6），本地正常答	本地生成，带引用	绿色「本地模型 · 知识库作答」
命中，本地输出拒答语	缓冲拒答，改走云端（带资料）	收到 `route` 后变蓝色「云端模型 · 通用建议」
不命中（<0.6），auto	直接把问题发云端（不带资料）	蓝色「云端模型」，原因写明分数低于阈值
不命中，`kb_only`	本地固定拒答，不联网	绿色「本地模型 · 已拒答」

为什么缓冲本地拒答：流式生成时，如果模型先吐出「知识库中暂无相关记录」，前端会先显示拒答卡片，几百毫秒后又变成云端答案，体验很差。因此本地流式输出先进入缓冲区：只要还是拒答语前缀就继续攒；一旦分叉，确认是正常答案，把缓冲一次性发出；如果完整输出就是拒答语，丢弃缓冲并发 `route` 切云端。用户要么看到完整的本地答案，要么直接看到云端答案，不会看到「拒答 → 又 answer」的闪烁。

云端提示词的三条边界：只答注塑相关（无关问题输出固定拒答语）；资料优先，资料不足时用【通用建议】开头并提示「需现场确认」，不得编造报警代码、型号参数、厂家数据；涉及拆机、带电、高温必须提醒断电挂牌、冷却、持证操作。第一版提示词要求「资料不足就拒答」，结果「螺杆磨损」这种领域相关但手册没写的问题也被拒；后来改成「只有完全无关才拒答，领域相关问题允许通用建议」，才达到设计目的。

隐私边界：本地路径问题、检索、生成全在本机；云端路径只发送「用户问题 + 检索到的片段（仅本地判断资料不足时）」，不上传整个知识库或文档原文件；无命中直接上云时只发送问题本身。`ROUTE_MODE=kb_only` 可完全禁用云端。

4.5 确定性故障诊断状态机

大模型做多轮追问很自然，但安全敏感场景有三个硬约束：**安全**（电气、高温检查顺序错了可能伤人，第一步必须是安全确认）、**可审计**（处置单每步为什么问、依据哪本手册哪一节必须固定可查）、**可复现**（同一症状同样回答应得到同样结论）。因此流程控制交给确定性状态机，自然语言解释留给问答模块。

整条链写在 `_TOPICS` 字典里：每个节点有题干、提示、手册依据 `basis`、选项；选项的 `next` 指向下一节点，带 `conclusion:` 前缀表示直接到结论。当前主题「料筒温度异常 A-101」包含 **12 个节点、11 个结论**，覆盖单区降温、温度波动、局部过热、多区同时下降四类现象，并配有「电阻测量方法」「端子检查方法」等操作指引节点，用户选「不会测」时先给方法再回到原问题。

```
安全确认 → 现象判断 → 加热圈电阻 → 接线端子 → 热电偶比对 → 固态继电器 → 结论
                ├─ 温度波动 → 传感器检查 → SSR 测试
                ├─ 局部过热 → 过热来源判断
                └─ 多区下降 → 供电检查
每个节点：题干 + 提示 + 手册依据（文档名/编号/章节/原文）+ 选项（safe/warn/danger）
每个选项：next 节点或 conclusion；带 conclusion 时生成报告
```

会话存在内存字典并加锁，每条 2 小时 TTL；`history` 是栈，回退时弹出最后一条并把当前节点指回该节点，同时清空结论和报告，避免残留旧分支。报告编号格式 `CZ-YYYYMMDD-XXXXXX`，日期便于和设备科纸质单对应，随机后缀避免同一天重号。

4.6 MCP 工具化与安全可控

知识库检索封装为 MCP Server（stdio），暴露两个工具：`search_knowledge(query, top_k=4)` 返回 JSON（`query/max_score/min_sim/has_relevant/hits`，hits 含文档名、编号、类别、章节、分数、原文）；`list_documents()` 返回文档数量与清单。工具描述明确写「`has_relevant=false` 时不要编造答案」，把拒答约束传给调用方。

选择 stdio 而非远程 HTTP：零端口、零鉴权，适合本机/内网 Agent；工具只读，不提供导入/删除，避免外部 Agent 误删知识库；返回值不含密钥、路径与模型配置。若要远程共享，需要额外的鉴权、多租户与限流层，当前不做。

安全与可控还体现在：提示词禁止编造报警代码/参数；云端只处理低置信问题；拒答时来源置空；MCP 只读；密钥只在 `.env`；诊断处置单明确写「处置前请由设备主管复核」，系统定位是辅助排查而非替代设备科。

CHAPTER 05

功能实现

5.1 问答界面与引用展示

问答页由三部分组成：中间对话流、右侧链路监视、底部输入区。空状态给 4 个示例问题（开机检查、温度异常、飞边、触电应急），点一下直接提问。回答流式出现时，右侧实时显示检索最高分、阈值、路由决定、首字与总耗时、来源数量；生成结束后把最后一条用户消息对齐到视野顶部，避免引用卡片把答案顶出屏幕。



图 5-1　本地问答：top-1 0.78 ≥ 阈值 0.60，绿色「本地模型」标签，答案下方为可展开的引用卡片

引用卡片展示序号、文档名、文档编号、类别、章节路径、相似度与原文片段。正文里的 `[1]` 由 Markdown 渲染为可点击标记，点击后滚动到对应卡片并高亮；引用编号与提示词编号同源生成，前端不做字符串匹配。引用卡片展示前会去掉 Markdown 的井号、加粗星号等标记，保证原文摘录可读。

5.2 路由可视化与错误处理



图 5-2　云端升级：本地资料不足后自动切换 DeepSeek，标签变蓝，右侧写明切换原因与「通用建议」性质

SSE 事件顺序为 `meta → route? → delta → done`，失败时发 `error`。`meta` 带初始路由、模型、分数、阈值与来源；`route` 仅在切换云端时出现；`done` 重发完整答案，前端用它覆盖增量，避免网络分块造成漏字。生成中可点「停止」，通过 `AbortController` 中止并提示「以上内容可能不完整」。云端失败不会静默吞掉：非流式回退本地拒答并带 `cloud_error`，流式发 `error` 卡片。

5.3 故障排查与处置单

诊断页左侧是步骤轴（已完成打勾、当前高亮），中间是问题卡（题干、提示、选项色条、可折叠手册依据），右侧是进度。支持「上一步」回退；完成态渲染处置单：报告编号、设备、现象、逐步过程表、结论等级、处置建议、安全提示、引用清单与签字栏。打印样式在 `@media print` 下切白底黑字，`@page` 定义 A4，处置单自身 14mm 内边距，表格行 `break-inside: avoid`；已用 Chrome `Page.printToPDF` 实测两页无裁切。网页、打印、Markdown 三种形态由同一份结构化报告生成。



车间智答
设备故障处置单 · FAULT DISPOSITION SHEET

处置单编号
CZ-20261105-8B1109

立即处置

固态继电器（SSR）损坏，需更换

SSR 不导通会导致加热输出中断；击穿常通则会造成持续加热、实际温度不可控，两种情况都需更换同规格 SSR。

设备	故障主题
海天 SA-1600II 注塑机（1600 kN）	料筒温度异常（A-101）
故障现象	生成时间
单个温区持续下降、加热不足	2026/11/5 06:26:41

01 排查过程

步骤	检查项	结果	手册依据
1	安全确认	已停机、断电、挂牌并冷却	FC-T-001 · 三、排查步骤 第 2 步 / 六、安全提示
2	现象判断	单个温区持续下降、加热不足	FC-T-001 · 三、排查步骤 第 1 步
3	加热圈电阻	35～45 Ω（正常范围）	FC-T-001 · 三、排查步骤 第 3 步
4	接线端子	端子干净、紧固、无烧蚀	FC-T-001 · 三、排查步骤 第 4 步
5	热电偶比对	偏差在 ±3 ℃ 以内	FC-T-001 · 三、排查步骤 第 5 步
6	固态继电器	不导通或指示灯不亮	FC-T-001 · 三、排查步骤 第 6 步

02 诊断结论

SSR 不导通会导致加热输出中断；击穿常通则会造成持续加热、实际温度不可控，两种情况都需更换同规格 SSR。

03 处置建议

1. 断电挂牌，确认加热回路无电。
2. 更换同规格固态继电器，检查散热与负载接线。
3. 送电测试加热输出通断正常。
4. 观察温度 30 分钟，确认无持续加热或温度失控。

04 安全提示

SSR 输出端可能带 380 V 电压，必须由持证电工测量。

05 依据出处

1. **《故障案例卡——料筒温度异常（A-101）》（FC-T-001）** 三、排查步骤 第 2 步 / 六、安全提示
   将设备切到手动，停止油泵，切断总电源，挂“禁止合闸”牌，等待料筒冷却至 50 ℃ 以下。更换加热圈必须断电挂牌，待料筒冷却至 50 ℃ 以下，佩戴耐高温手套。
2. **《故障案例卡——料筒温度异常（A-101）》（FC-T-001）** 三、排查步骤 第 1 步
   进入报警历史，确认 A-101 首次出现时间；查看温度趋势，判断是单区异常还是多区同时下降。单区异常优先查该区加热回路。
3. **《故障案例卡——料筒温度异常（A-101）》（FC-T-001）** 三、排查步骤 第 3 步
   该机加热圈额定 3.5 kW/380 V，正常冷态电阻 35～45 Ω；测得无穷大说明开路，需更换。
4. **《故障案例卡——料筒温度异常（A-101）》（FC-T-001）** 三、排查步骤 第 4 步
   检查加热圈与电箱端子排连接，端子发黑、烧蚀、松动会导致接触电阻过大，需打磨或更换端子并复紧。
5. **《故障案例卡——料筒温度异常（A-101）》（FC-T-001）** 三、排查步骤 第 5 步
   检查热电偶插入深度和固定螺丝，接线端子有无氧化；用标准温度计比对，偏差超过 ±3 ℃ 更换热电偶。
6. **《故障案例卡——料筒温度异常（A-101）》（FC-T-001）** 三、排查步骤 第 6 步
   给 SSR 输入信号，测量输出端是否导通；指示灯不亮或输出无电压，判定 SSR 损坏并更换同规格固态继电器。

处置人：_____　审核人：_____　日期：_____

本处置单由「车间智答」故障排查向导依据厂内知识库生成，处置前请由设备主管复核。

图 5-3　处置单打印视图：结论、排查过程、处置建议、安全提示与 6 条手册依据

5.4 知识库管理与检索测试台

知识库页展示文档数、切片数、类别数与当前阈值；文档表含编号、标题、类别、版本、切片数、导入时间与操作。支持全量导入、重建索引、上传 `.md/.txt`、删除（二次确认，源文件移入 `.trash`）。检索测试台输入问题后展示 top-4 片段、相似度与是否过阈值，演示时可现场改问题观察分数变化。

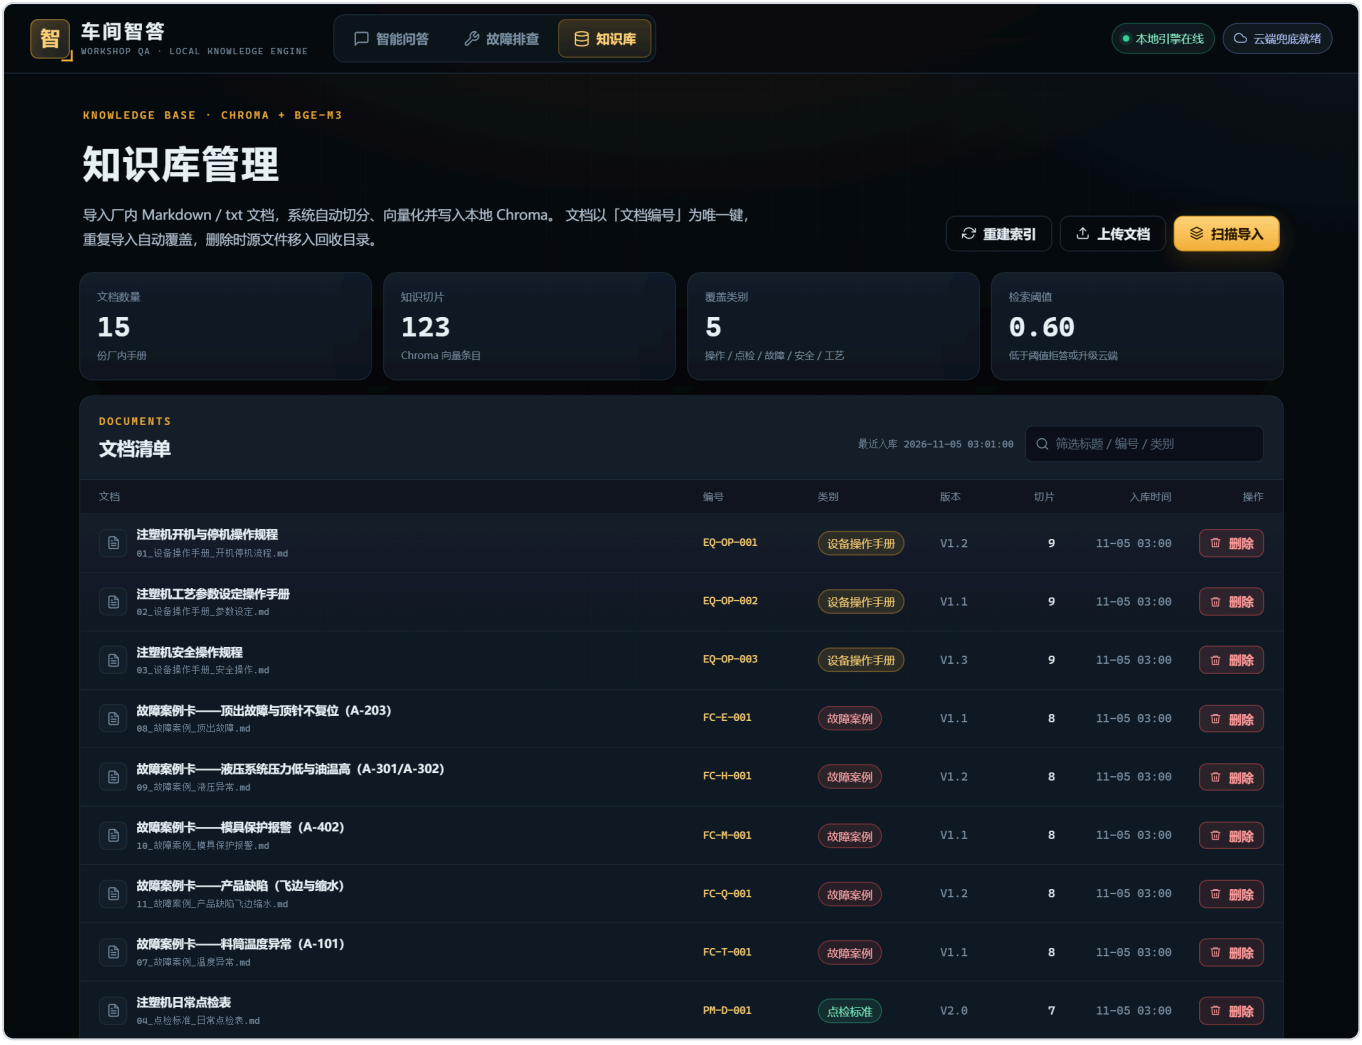


图 5-4　知识库管理：统计卡、文档清单、导入/重建入口与检索测试台

5.5 SSE 协议与工程结构

事件	时机	字段
`meta`	检索完成、生成前	`route/route_reason/model/max_score/min_sim/refused/grounded/sources[]`
`route`	本地切云端	新 `route/route_reason/model/grounded/sources`
`delta`	每小段生成	`content`
`done`	生成结束	`answer/route/model/refused/grounded/sources`
`error`	检索或生成失败	`message`

```
backend/
  app/
    main.py             FastAPI 入口、/health、静态前端托管
    config.py           .env 读取、路径解析、阈值与路由参数
    routers/            kb.py / chat.py / diag.py
    services/           chunking.py / embeddings.py / kb.py / chat.py / cloud.py / diagnosis.py
  mcp_server.py         MCP stdio Server
  scripts/              calibrate.py / acceptance_routes.py / test_mcp_client.py
frontend/src/
  App.vue               外壳、导航、健康状态、KeepAlive
  components/           ChatView / DiagnosisView / KnowledgeView / SourceCard / RouteBadge / Icon
  lib/                  api.ts（含 SSE 解析）/ types.ts / markdown.ts
  style.css             设计令牌与基础组件
```

CHAPTER 06

测试与部署

6.1 测试方法与功能验收

测试采用「接口脚本 + 浏览器真实交互」两条线：脚本负责可复现的数值与事件序列（写入 `docs/evidence/`），浏览器负责界面、流式、引用点击、打印版式等体验验收（headless Chrome CDP 截图与 PDF）。环境为 Windows 11、Ollama 本地 Qwen2.5-7B q4_K_M + bge-m3、FastAPI 127.0.0.1:8000、知识库 15 份文档 / 123 切片、阈值 0.6。

验收项	标准	结果	证据
本地问答	答案正确，出处对得上	**通过**	top-1 0.7833；引用 EQ-OP-001/003、PM-D-001
无依据拒答	知识库没有的问题必须拒答	**通过**	0.4242 < 0.6；`refused=true`，来源空
故障诊断链	完整走完并生成处置单	**通过**	6 步；报告 CZ-20261105-070AF4；A4 两页
端云路由	一易一难触发两种路径并标注	**通过**	本地 0.7833；云端 0.6589 触发 `route→cloud`
MCP	客户端调用成功并返回结果	**通过**	`max_score=0.8078`，15 份文档
公网部署	外网可访问并完成自测	**待服务器**	本地生产态已通过；脚本与文档就绪

6.2 关键实验数据

阈值校准：正向 15 条最低 0.675 / 平均 0.754；负向 8 条最高 0.522 / 平均 0.378；灰区 7 条 0.436 ~ 0.617；最终 0.6。

路径	问题	top-1	结果
本地	注塑机开机前需要检查什么?	0.7833	本地作答，首字约 1.0 s，引用 3 份文档
云端升级	注塑机螺杆磨损到什么程度必须更换?	0.6589	本地拒答 → 切 `deepseek-chat`，首字约 3.3 s，标【通用建议】
拒答	如何做红烧肉?	0.4242	`refused=true`，`sources=[]`，不列出处

诊断链路：安全确认 → 现象判断 → 加热圈电阻（35 ~ 45 Ω 正常）→ 接线端子（干净紧固）→ 热电偶比对（±3 ℃ 内）→ 固态继电器（不导通），结论「固态继电器（SSR）损坏，需更换」，6 条依据全部来自 FC-T-001，报告编号 CZ-20261105-070AF4。

MCP：官方客户端 `list_tools` 发现 2 个工具；`search_knowledge("料筒温度异常怎么排查", top_k=3)` 返回 `has_relevant=True`、`max_score=0.8078`，top-3 均命中 FC-T-001；`list_documents` 返回 15 份。

6.3 性能与部署

开发机 GPU 环境下生成速度约 63.8 tok/s；本地热态首字 0.25–1.0 s，完整回答 4.3–6.5 s；云端首字 2.35–3.3 s；检索热态约 0.5 s。首次加载模型需 10～30 s，模型以 `keep_alive=30m` 常驻。

部署形态：Nginx 监听 80/443，反向代理到 `127.0.0.1:8000`；FastAPI 托管前端 `dist`，并连接本机 Ollama 与 Chroma。`deploy/setup.sh` 负责首次初始化（apt 依赖、Node 20、运行用户、venv、构建、systemd、Nginx），`deploy/deploy.sh` 负责日常更新（`git pull --ff-only` → 依赖 → 构建 → 重启 → 健康检查）。Nginx 必须设置 `proxy_buffering off`、`proxy_cache off`、`X-Accel-Buffering: no`，否则 SSE 会退化成一次性返回。

配置项	值 / 说明
后端进程	systemd `workshop-qa.service`，`--workers 1`（诊断会话在内存）
监听地址	后端仅 `127.0.0.1:8000`，外网必须经 Nginx
密钥	`backend/.env`，权限 600，属主 `workshop`，不入库
HTTPS	有域名时 certbot + nginx 插件；国内服务器需备案
运行用户	`workshop`（无登录 shell），数据目录同属主

6.4 安全清单与已知限制

安全项	状态	说明
密钥只在 .env，仓库只有 .env.example	**已落实**	代码不写默认 Key；部署脚本 chmod 600
上传文件名去路径，防目录穿越	**已落实**	只接受 .md/.txt，UTF-8 解码
删除文档移入 .trash	**已落实**	避免误删不可恢复
MCP 工具只读	**已落实**	不提供导入/删除
云端只发问题与必要片段	**已落实**	kb_only 可完全禁用
公网访问鉴权 / 速率限制	**未做**	演示阶段开放；正式给工厂用需登录/白名单与 Nginx limit_req

已知限制：

- 诊断只做了「料筒温度异常」一个主题；引擎可复用，其余主题是往 `_TOPICS` 加数据；
- 诊断会话在进程内存，重启丢失，不支持多副本；扩容需迁 Redis；
- 拒答判断依赖模型遵循固定拒答语，换模型需回归测试；
- 未做 rerank；知识库上千后应加 cross-encoder 重排；
- 校准样本 30 条，换一批文档需重跑 `calibrate.py`；
- 公网部署、HTTPS、访问鉴权待服务器信息到位后完成。

CHAPTER 07

总结与展望

7.1 完成情况

作品已完成知识库与 RAG 问答、两层拒答、端云协同路由、故障排查状态机与处置单、MCP 工具封装、三视图前端与本地生产态部署验证。任务书要求的核心功能全部打通并有实测留痕；公网部署因缺少服务器信息暂缓，部署脚本、systemd/Nginx 配置与自测清单已准备完毕。

7.2 技术创新点与应用创新点

技术创新点

1. **可校准的两层拒答 + 缓冲式路由**：用 30 条问句实测出 0.6 阈值，检索层与生成层分工；本地拒答先缓冲，确认升级云端后才发 `route` 事件，避免界面「拒答又变答案」的闪烁。这条链路在常见 RAG 演示中较少见，且可复现。
2. **确定性工作流与生成式问答分工**：安全敏感的排查路径交给状态机，自然语言解释交给 RAG；同一输入得到同一结论，每步有手册依据，输出结构化处置单。相比「让大模型自由追问」，更可审计、可追责。
3. **知识库能力的 MCP 化**：检索与文档清单封装为标准 MCP 工具，工具描述携带拒答约束，可被 Claude Desktop、IDE 等客户端复用，而不是锁死在网页里。
4. **端到端可溯源**：引用编号与 `sources.index` 同源生成，前端按 index 映射；路由原因、检索分数、耗时全部可见，演示时每个结论都能落到证据。

应用创新点

1. **数据不出厂的 AI 助手**：本地优先 + 云端兜底，回应了工厂对设备参数、工艺数据外泄的核心顾虑；断网时本地问答仍可用。
2. **把「老师傅经验」变成可查流程**：故障案例卡 + 状态机 + 处置单，让新人有路径可走，让老师傅的判断标准沉淀为可审计的记录。
3. **面向一线的界面**：深色高对比、大字号、少层级、手机可用；引用可点开、路径有标签，不用理解「RAG」「向量」也能用。
4. **低成本可复制**：单台带 GPU 的工控机/服务器即可运行，模型量化后 4.7 GB；部署脚本与文档齐备，便于其他车间复制。

7.3 不足与展望

当前版本的不足主要在覆盖广度与生产化：只做了一条诊断链，未做多设备类型；没有登录与权限，公网演示阶段靠网络边界；会话存在内存，不能多副本；未做 rerank 与答案逐句校验。下一步计划：

- 把顶出、液压、模具保护等主题按同一引擎补进 `_TOPICS`，形成注塑机故障图谱；
- 诊断会话迁 Redis，支持多副本与断点续查；
- 检索加 cross-encoder 重排，文档上千后保持 top-4 精度；
- 增加登录、角色与审计日志，满足工厂正式上线的权限要求；
- 在服务器到位后完成公网部署、HTTPS 与外网自测；

- 探索拍照 + 云端 VL 的多模态入口，但坚持「本地优先、图片不出厂除非用户确认」。

> **一句话总结：**车间智答不是「让大模型什么都答」，而是让它在正确的资料、正确的路径和正确的边界内作答；答不了就明确说答不了，并把判断依据留给用户复核。

APPENDIX A

附录 A　AI 生成代码说明

按赛事要求，如实说明 AI 在作品开发中的参与范围。本项目在开发过程中使用了 AI 编程助手 **Claude Code** 辅助生成代码、示例知识库文档与文档初稿；运行时的 Qwen2.5 与 DeepSeek 是产品功能的一部分，不参与代码生成。

A.1 使用原则

- 需求、技术选型、验收标准由团队确定；AI 负责起草实现，团队逐模块运行、审查、提出修改；
- AI 生成内容不直接视为正确：每个接口、每条诊断分支、每个前端交互都经过实际运行与验收；
- 密钥、账号、服务器信息不交给 AI 生成或保存；仓库只保留 `.env.example`；
- 示例知识库为围绕注塑机自编的演示数据，数值为行业常识范围内的合理值，不来自真实工厂，也不抄网上现成手册。

A.2 分模块说明

模块	AI 参与	人工工作
切分 / 向量化 / 检索	生成切分、入库、检索代码初稿	确定标题栈、600/80 参数；跑 30 条校准；修正空索引 `min_sim` 缺陷
RAG 生成 / 拒答	生成提示词、流式生成、引用组装初稿	实测本地/拒答用例；调整拒答语与来源置空逻辑
端云路由	生成路由、云端调用、缓冲拒答初稿	实测两种路径；第一版云端提示词过严，团队发现后改为「通用建议」边界
诊断状态机	生成节点数据、会话、报告与 Markdown 初稿	按 FC-T-001 核对 12 节点/11 结论；走完整链；验证回退与 A4 打印
前端三视图	生成 Vue 组件、设计令牌、SSE 解析初稿	浏览器逐页验收；修复自动滚动遮答案、拒答标签、引用 Markdown 符号、打印裁切
MCP Server	生成工具封装与客户端验收脚本	升级 MCP 2.x 解决依赖冲突；用官方客户端实测调用
示例文档	生成 15 份注塑机文档初稿	检查数值、步骤、安全提示的一致性；确保不抄现成手册
部署脚本	生成 setup/deploy/systemd/Nginx/说明初稿	Bash 语法检查；本地生产态单端口验证；公网执行待服务器
设计说明 / 本文档 / 视频脚本	生成初稿与排版	团队复核事实与数据；替换队伍信息；对最终内容负责

A.3 人工验证方式

每个模块完成后执行对应验收：RAG 用「可回答问题 + 无关问题」实测；路由用「易/难」两问并检查 SSE 事件序列；诊断从安全确认走到结论并打印 PDF；MCP 用官方客户端 `list_tools` 与调用；前端用 headless Chrome 截图与 390×844 移动端检查。原始结果保存在 `docs/evidence/`，汇总在 `docs/acceptance.md`。

A.4 责任声明

团队对作品的全部代码、文档、示例数据与演示内容负责。AI 是开发工具，不替代团队的设计判断、测试与答辩解释；文档中的技术决策、参数与实测数据均可由仓库脚本复现。若评审需要，团队可说明任一模块的生成过程与人工修改点。

APPENDIX B

附录 B　复现与接口

B.1 本地启动

```
# 1) 本地模型
ollama pull qwen2.5:7b-instruct-q4_K_M
ollama pull bge-m3

# 2) 后端
cd backend
python -m venv .venv
.venv/Scripts/pip install -r requirements.txt      # Linux: .venv/bin/pip
cp ../.env.example .env                             # 填 DEEPSEEK_API_KEY（可选）
.venv/Scripts/python -m uvicorn app.main:app --host 127.0.0.1 --port 8000

# 3) 前端（开发）
cd frontend && npm ci && npm run dev                # http://localhost:5173

# 4) 生产态（单端口）
cd frontend && npm run build
cd ../backend && .venv/Scripts/python -m uvicorn app.main:app --port 8000
# 打开 http://127.0.0.1:8000/
```

B.2 验收命令

```
# 导入知识库
curl -X POST http://127.0.0.1:8000/api/kb/import

# 30 条阈值校准
backend/.venv/Scripts/python.exe backend/scripts/calibrate.py

# 路由三路径 + 诊断链路（写入 docs/evidence/）
backend/.venv/Scripts/python.exe backend/scripts/acceptance_routes.py

# MCP 客户端
backend/.venv/Scripts/python.exe backend/scripts/test_mcp_client.py
```

B.3 API 摘要

方法 / 路径	说明
`GET /health`	模型、阈值、路由模式、前端构建状态
`POST /api/kb/import`	导入 `data/docs`；`?rebuild=true` 全量重建
`POST /api/kb/search`	向量检索：片段、分数、`has_relevant`
`POST /api/chat/stream`	SSE：`meta → route? → delta → done/error`
`GET /api/diag/topics`	诊断主题列表

方法 / 路径	说明
`POST /api/diag/sessions`	开始诊断会话
`POST /api/diag/sessions/{id}/answer`	提交当前步骤选择
`GET /api/diag/sessions/{id}/report.md`	下载 Markdown 处置单

B.4 主要环境变量

变量	默认	说明
`LLM_MODEL`	qwen2.5:7b-instruct-q4_K_M	本地生成模型
`EMBED_MODEL`	bge-m3	向量模型
`RETRIEVAL_MIN_SIM`	0.6	拒答阈值
`ROUTE_MODE`	auto	auto 允许云端；kb_only 严格本地
`DEEPSEEK_API_KEY`	空	只填在 `backend/.env`
`DEEPSEEK_MODEL`	deepseek-chat	云端模型

完整设计说明见仓库 `docs/`：chunking / retrieval / rag-generation / routing / diagnosis / mcp / frontend / deployment；逐项验收见 `docs/acceptance.md`。